Universidad Intercontinental de la Empresa

Proyecto

Aprendizaje Automático

Borja González Seoane

S03, 16 de septiembre de 2026

1. Descripción general de la actividad

Tal y como consta en el Contrato de Enseñanza-Aprendizaje, la AE03, con un peso del 25 % en la calificación final, consiste en la realización de un proyecto en el que se pretende que se apliquen la totalidad de los conocimientos adquiridos en la asignatura. Esta actividad permitirá a los estudiantes trabajar en un proyecto de aprendizaje automático de principio a fin, desde la obtención de los datos hasta la presentación de los resultados, constituyendo de esta forma una experiencia de aprendizaje holística que integrará todas las unidades del currículo del curso.

Del 25 % de la calificación, el 20 % se corresponde con la entrega final y su exposición en la última sesión del curso, S15, mientras que el 5 % restante se podrá sumar en dos puntos de control (2,5 % cada uno) que tendrán lugar en las sesiones S09 y S12, tal y como se detalla en la planificación de la Sección 3 del Contrato de Enseñanza-Aprendizaje. En estos puntos de control se comprobará si se está avanzando correctamente en el proyecto y se resolverán dudas que puedan surgir. Esta actividad no está sujeta a recuperación.

La tarea se llevará a cabo en equipos de trabajo de cuatro estudiantes. Todos los equipos deberán integrar a estudiantes de ambos campus. Los equipos deberán registrarse mediante un mecanismo dispuesto para dicho fin en el Campus Virtual, con fecha límite en la sesión S04.

Para la realización del proyecto se proporcionará un conjunto de datos en el Campus Virtual de la asignatura, con el que trabajarán todos los grupos. Este conjunto de datos permitirá desarrollar diferentes líneas de trabajo de aprendizaje automático. Cada equipo deberá trabajar en todas ellas, entrenar un modelo que resuelva cada una y presentar los resultados obtenidos en una exposición final.

2. Detalle de los objetivos de la actividad

Los objetivos de la actividad, que deberán perseguir todos los equipos, son los siguientes:

1. Analizar el conjunto de datos proporcionado, realizando un EDA exhaustivo para comprender la estructura de los datos y las relaciones entre las variables.

2. Preprocesar los datos, realizando las transformaciones necesarias para que los modelos de aprendizaje automático puedan ser entrenados. Podrían ser necesarios distintos preprocesamientos para cada una de las líneas de trabajo a modelar.

3. Para cada una de las líneas de trabajo planteadas con respecto al conjunto de datos, entrenar un modelo y evaluar su rendimiento. Se valorará el probar diferentes arquitecturas de modelos para las tareas, así como diferentes estrategias de entrenamiento y validación, hiperparametrización, etc. Se trata de intentar emplear la mayor cantidad de técnicas aprendidas en la asignatura posible, siempre y cuando se justifique su uso racionalmente.

4. Servir los modelos finales tras una API común, definida por el profesor y cuyo contrato se publicará más adelante, de modo que puedan ser consultados de forma homogénea y sin necesidad de conocer los detalles de su implementación.

5. Presentar una exposición oral final, en la que se deberá explicar el proceso seguido, las decisiones tomadas y los resultados obtenidos. Se valorará la claridad y la capacidad de comunicación de los estudiantes, más allá de la calidad de los resultados o la solidez técnica del trabajo.

Para esta actividad se pretende que los equipos trabajen de forma autónoma, como si de un proyecto real se tratase. La profundidad de la experimentación, los distintos ensayos y errores acometidos durante el semestre, será especialmente valorada. Se insta pues a los estudiantes a que lleven un registro de todas las decisiones tomadas, los problemas encontrados y las soluciones propuestas, y que incorporen toda esta información en la presentación final.

Se espera que los estudiantes sean capaces de tomar decisiones y resolver problemas de forma autónoma, aunque siempre podrán contar con la ayuda del profesor para resolver dudas o problemas que puedan surgir.

Versión parcial del enunciado

Este documento ya incluye el **conjunto de datos y las líneas de trabajo** del proyecto. Queda por publicar la sección relativa al **contrato de la API común** tras la que deberán servirse los modelos, que se revelará en la sesión S07, cuando se aborde el servicio y la apificación de modelos en la Unidad III. Se avisará en el Campus Virtual cuando se publique la versión ampliada de este enunciado.

3. Conjunto de datos y líneas de trabajo

El conjunto de datos proporcionado para la realización del proyecto está disponible en el Campus Virtual de la asignatura, en el archivo `proy_diabetes_dev.csv` —*proyecto-diabetes-partición de desarrollo (*development*)*—.

El contexto es el de un consorcio de centros de atención primaria que desde hace años realiza una encuesta anual de salud entre su población adscrita. En ella se recogen indicadores clínicos básicos (índice de masa corporal, presión arterial, colesterol), hábitos de vida (tabaquismo, actividad física, consumo de fruta y verdura, consumo de alcohol) y una autovaloración del estado de salud, junto con variables sociodemográficas. El consorcio quiere pasar de usar esa encuesta como mero informe descriptivo a explotarla para orientar sus programas de prevención.

La responsable de sistemas de información del consorcio ha decidido iniciar un proyecto basado en aprendizaje automático que permita caracterizar mejor a la población atendida y anticipar tanto el riesgo metabólico como la carga de enfermedad. Es aquí donde los equipos de estudiantes de esta asignatura entran en juego.

Por motivos de privacidad y protección de datos, el consorcio ha ofuscado toda la información de carácter personal que figuraba en su sistema: columnas como `dni`, `nombre`, `apellidos`, `direccion`, `telefono`, `email` o `num_historia_clinica` aparecen en el archivo sustituidas por cadenas aleatorias. Se mantienen en la extracción porque así salen del sistema de gestión del consorcio, pero se advierte de que no aportan absolutamente nada al modelado y de que su tratamiento está sujeto a la normativa de protección de datos.

Tras una primera toma de requisitos con la responsable de sistemas de información, se han planteado tres líneas de trabajo de alto nivel para el proyecto:

1. **Clusterización:** el consorcio quiere identificar perfiles de paciente para poder dimensionar y dirigir sus programas de prevención. Así pues, el propósito sería hacer emerger algunos grupos de pacientes con características similares. Estos clústeres deberán ser fáciles de explicar y de interpretar: un grupo que no se pueda describir en una frase a un profesional sanitario no le sirve a nadie.

2. **Clasificación:** se pretende predecir si un paciente presenta **diabetes** (variable `diabetes`) a partir del resto de indicadores recogidos en la encuesta. El objetivo es disponer de una herramienta de cribado que ayude a priorizar a qué pacientes conviene citar para una prueba diagnóstica.

3. **Regresión:** se desea estimar el número de **días de mala salud física** que un paciente declara en el último mes (variable `dias_salud_fisica_mala`, un entero entre 0 y 30). Esta magnitud se emplea como indicador aproximado de carga de enfermedad y resulta útil para planificar la demanda asistencial.

Sobre la variable objetivo de la línea de regresión conviene hacer una advertencia: su distribución está fuertemente concentrada en el cero —la mayoría de los encuestados no declara ningún día de mala salud física— y presenta un segundo pico en el valor máximo, 30. No es una variable continua ordinaria y los equipos harán bien en analizar su distribución antes de elegir modelo y métrica.

Otra advertencia, esta de naturaleza metodológica y ética: la muestra facilitada **no refleja la prevalencia real** de la diabetes en la población, sino que ha sido remuestreada de forma estratificada para que aproximadamente un tercio de los registros correspondan a pacientes diagnosticados. Esto facilita el trabajo de modelado, pero invalida cualquier lectura epidemiológica directa de las cifras, y las probabilidades que devuelva un modelo entrenado sobre esta muestra no son probabilidades poblacionales. Se espera que los equipos recojan esta limitación en su informe.

Como comentarios generales, ha de tenerse en cuenta que como en cualquier base de datos del mundo real, pueden existir errores o inconsistencias, principalmente debidos a la recogida de datos: valores ausentes, variables que deberían ser binarias y que aparecen codificadas de varias formas distintas a lo largo del archivo, o columnas de gestión interna sin valor predictivo. Por otra parte, aunque el consorcio haya disponibilizado una muestra de su base de datos, es responsabilidad del equipo de trabajo seleccionar de la misma las variables que considere más relevantes para cada una de las líneas de trabajo planteadas, que no necesariamente han de ser todas las disponibles o todas para las tres líneas de trabajo.

4. Entrega y exposición final

En la última sesión del semestre, S15, se realizará la exposición final de los proyectos. Cada equipo dispondrá de 20 minutos para presentar los resultados obtenidos, explicar el proceso seguido y las decisiones tomadas. Se valorará la claridad y la capacidad de comunicación de los estudiantes. Todos los estudiantes del equipo deberán participar en la exposición de forma equitativa.

Además de la propia exposición, se dispondrá en el Campus Virtual una tarea para depositar los siguientes entregables antes del inicio de la S15:

1. Un informe en formato PDF con una extensión máxima de 10 páginas, en el que se detallen los objetivos del proyecto, el proceso seguido, los resultados obtenidos y las decisiones tomadas.

2. Las transparencias de la presentación final en formato PDF.

3. Un archivo comprimido ZIP con el código fuente del proyecto, incluyendo los *scripts* o *notebooks* de preprocesamiento, entrenamiento y evaluación de los modelos, así como cualquier otro archivo necesario para la reproducción de los resultados.

4. Los artefactos con los pesos de cada uno de los modelos finales de cada una de las líneas de trabajo, en otro archivo comprimido ZIP. **El profesor empleará estos archivos de pesos, así como el código fuente, para evaluar los modelos sobre una partición de datos que no ha sido vista por los estudiantes.** En caso de que el código no funcione correctamente o de que no sea posible reproducir los resultados con los pesos suministrados, la calificación de la actividad se verá afectada.

5. El código del servicio de la API común, sus artefactos y el archivo de dependencias necesario para levantarlo, según lo que establezca el contrato de la API común de la asignatura.

5. Criterios de evaluación

La evaluación de la actividad se realizará teniendo en cuenta los siguientes aspectos, que se recomienda que los estudiantes tengan en cuenta a la hora de realizar el proyecto:

1. Avance satisfactorio del proyecto en el primer punto de control, en la sesión S09 (2,5 %). Objetivos mínimos: se ha completado el análisis exploratorio de los datos y se ha implementado el código necesario para preprocesar los datos. Se tiene una versión preprocesada de los datos para comenzar a trabajar en el modelado de alguna de las líneas de trabajo.

2. Avance satisfactorio del proyecto en el segundo punto de control, en la sesión S12 (2,5 %). Objetivos mínimos: se ha trabajado en el modelado de al menos una de las líneas de trabajo. Se dispone de una versión preliminar de un modelo entrenado que presenta un comportamiento razonable. Además, el equipo deberá tener ya en marcha su servicio de API y ser capaz de demostrar en la sesión que responde correctamente, para al menos una línea de trabajo, a las peticiones previstas en el contrato de API común de la asignatura.

3. Calidad técnica general del proyecto (10 %), tras la entrega final. Se valorará la calidad técnica del proyecto, incluyendo la profundidad del EDA, la correcta implementación de las transformaciones de los datos, la elección de los modelos y la calidad de los resultados obtenidos. Transversalmente se valorará la limpieza y claridad del código fuente, así como la correcta organización del proyecto en *scripts* o *notebooks* fáciles de navegar y entender.

4. Calidad de la presentación final (5 %). Se valorará la claridad y la capacidad de comunicación de los estudiantes, más allá de la calidad de los resultados obtenidos o la solidez técnica del trabajo. Se valorará la capacidad de los estudiantes para justificar el proceso seguido y las decisiones tomadas.

5. **Fase competitiva (5 %). El profesor dispone de una partición de datos no vista por los estudiantes, pero perteneciente al mismo conjunto de datos. Se empleará esta partición para evaluar los modelos finales de cada una de las líneas de trabajo de cada uno de los equipos. Esta evaluación se ejecutará contra la API común de la asignatura: el profesor enviará las instancias retenidas a la API de cada equipo, una vez por cada línea de trabajo que esta declare servir, de modo que todos los modelos se midan exactamente con las mismas entradas y en las mismas condiciones. De esta forma, se obtendrán nuevas métricas con las que ponderar la capacidad de generalización de los modelos obtenidos. Se establecerá una ponderación de equipos en función de estas métricas y se escalará el 5 % en consonancia para premiar a los equipos con mejores resultados. Una línea de trabajo cuya API no responda correctamente, o que devuelva un número de predicciones distinto del número de instancias enviadas, no podrá ser evaluada en esta fase.**

   Esta fase competitiva se circunscribe a las líneas de **clasificación y regresión**, que son las que cuentan con una variable objetivo contra la que medir el error. La línea de **clusterización queda**

fuera de la ponderación competitiva: al no existir verdad-terreno, y siendo los identificadores de clúster arbitrarios y no comparables entre equipos, cualquier ranking automático premiaría la compacidad numérica de los grupos y no su utilidad, que es justamente lo que se pide. Dicha línea se evalúa, como el resto del trabajo, en los apartados de calidad técnica y de presentación final, donde pesan la interpretabilidad de los perfiles hallados y la justificación de las decisiones tomadas.